

# Modeling

---

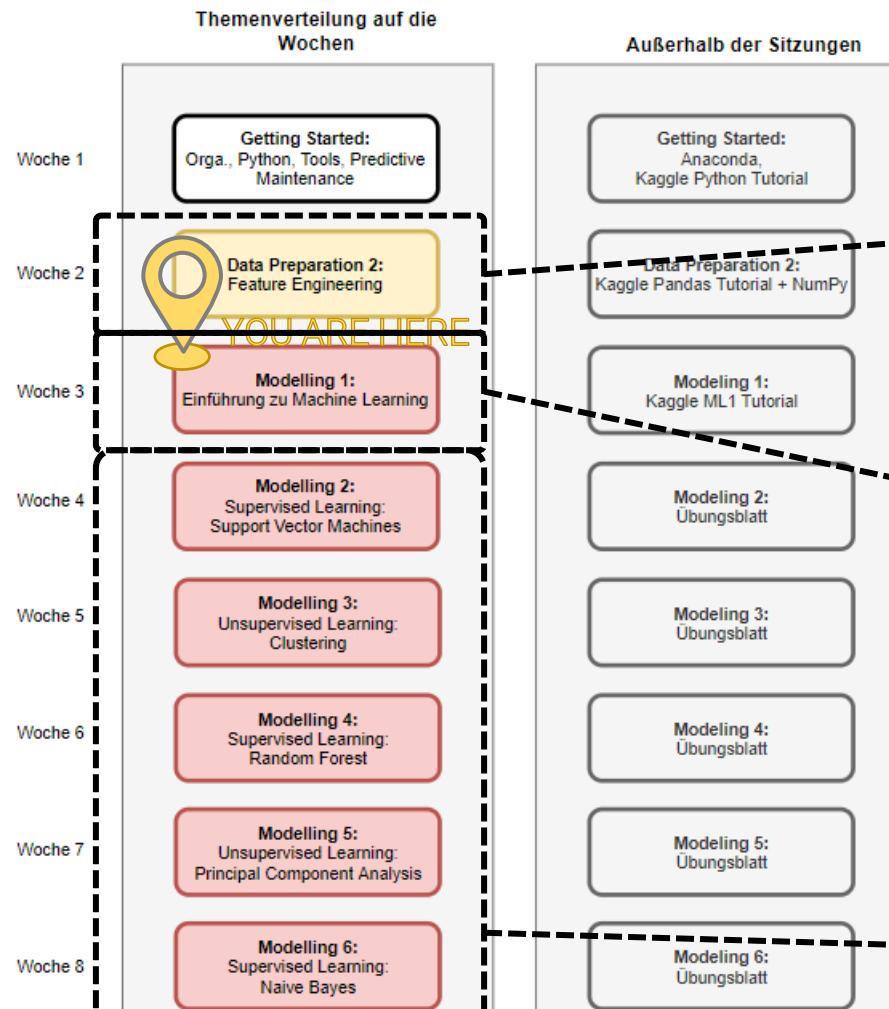
Einführung in Machine Learning

# Agenda


- 
1. Was ist Machine Learning?
  2. Kategorien des Machine Learning und qualitative Beispiele
  3. Machine Learning in Python: `scikit-learn`
  4. Hyperparameter und Model Validation
  5. Bias-Variance Trade-off
  6. Cross-Validation und Generalisierung
  7. Kostenfunktionen
  8. Machine Learning Pipelines (evtl. in der letzten Sitzung bzw. extra Foliensatz erstellen)



# Wo sind wir?



# Ausgangssituation



Wo befinden wir uns jetzt?

- Wir wissen jetzt was ein Feature ist
- Wir haben eine Vorstellung von einem Feature-Raum
- Wir wissen, wie Daten in einem Feature-Raum repräsentiert werden
- Wir wissen wie man Daten exploriert und „manuell“ Schlüsse zieht (deskriptiv und inferenzstatistisch)

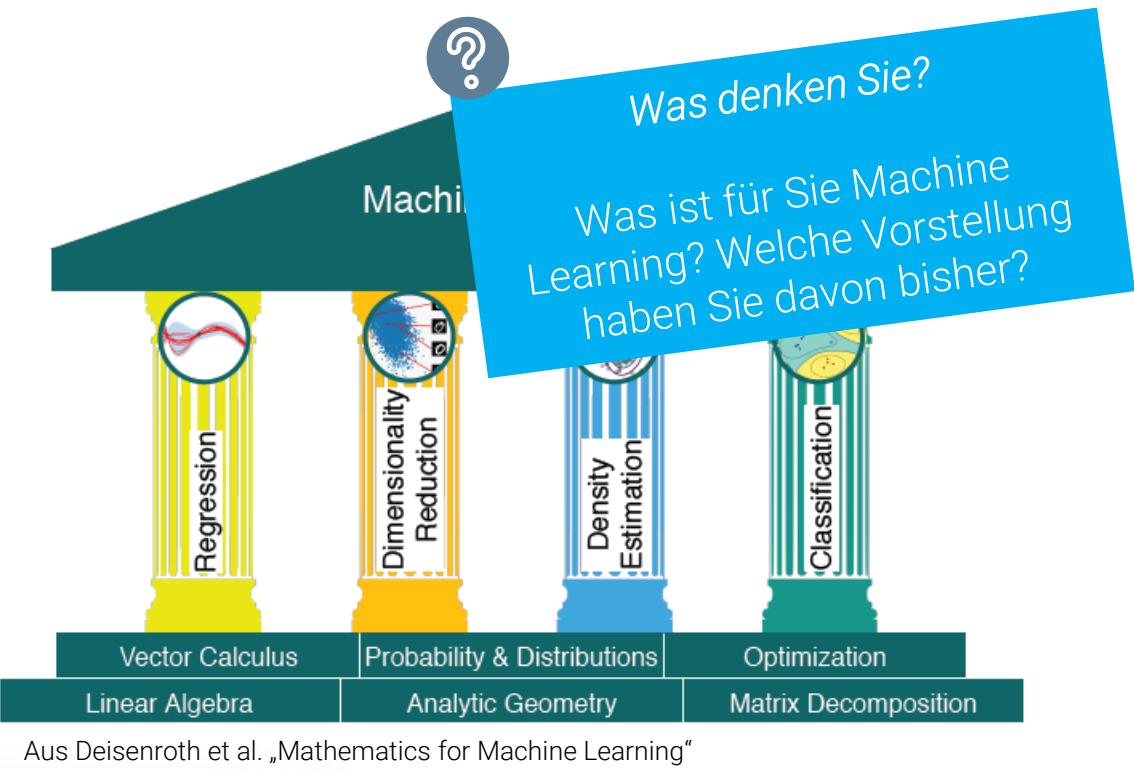
→ Nun wollen wir, dass Algorithmen für uns Schlüsse ziehen und Urteile fällen!



*So what?*

Interessanter Aspekt vorab: im Machine Learning bringen wir Algorithmen bei *wissenschaftlich zu Denken bzw. zu arbeiten*

# Was ist Machine Learning?



So what?

Wir führen in dieser Vorlesung die wichtigsten Konzepte des Machine Learning anhand einfacher und qualitativer Beispiele ein


Machine Learning == „Building Models of Data“

- Machine Learning zeichnet sich dadurch aus, dass mathematische Modelle entstehen, um zugrundeliegende **Daten** zu verstehen
- Diese Modelle werden an die **Daten angepasst**, damit sie diese so optimal wie möglich repräsentieren
- Diese Anpassung kann stattfinden, da Machine Learning Modelle „**tunable parameters**“ haben
  - Anpassung dieser auf die Daten
  - Das Modell **lernt** aus den Daten
- Nach diesem Lernprozess können trainierte Modelle dazu verwendet werden, um **Labels** ungesiehtener Daten vorherzusagen

Was denken Sie?

Was suchen also Machine Learning Modelle?

# Kategorien des Machine Learning: Überblick



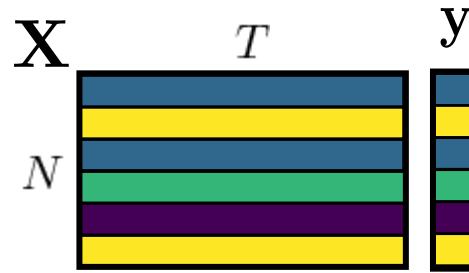
## Unsupervised Learning

- Modellierung der Eigenschaften/Struktur von Daten **ohne** zugehörige Labels
- Man versucht durch Heuristiken Erkenntnisse aus den Daten zu gewinnen
- „Den Datensatz für sich sprechen lassen“
- **Große Unterkategorien**
  - Clustering und Dichteschätzung
  - Dimensionsreduktion

## Supervised Learning

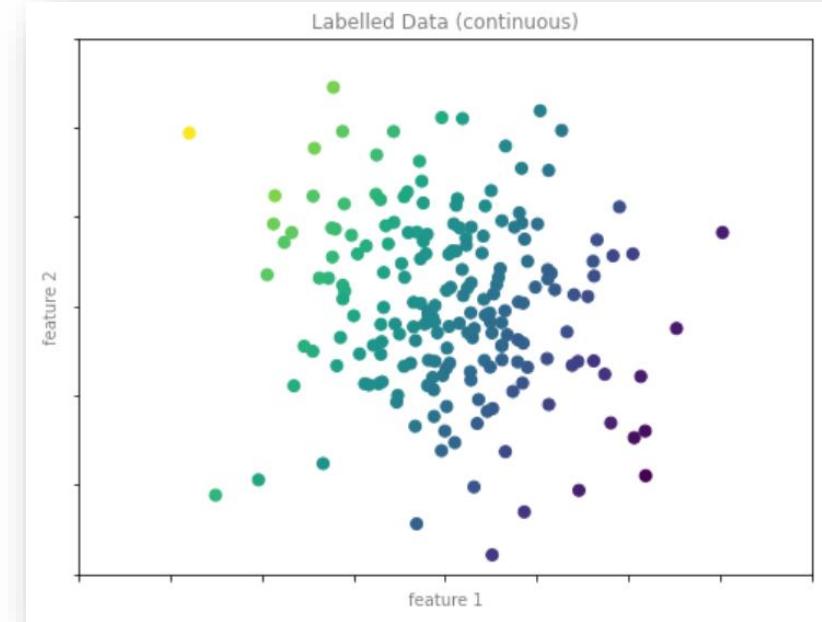
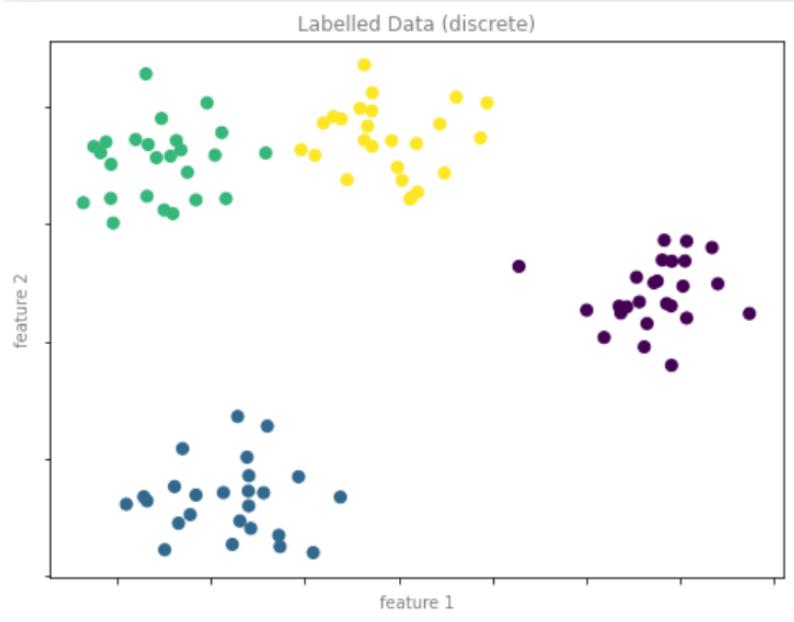
- Modellierung der Abhängigkeiten von beobachteten **Features** und zugehörigen **Labels**
- Nach dem Training kann das Modell Labels zu Features neuer Beobachtungen zuordnen
- **Große Unterkategorien**
  - Klassifikation
  - Regression

# Supervised Learning: Datensicht



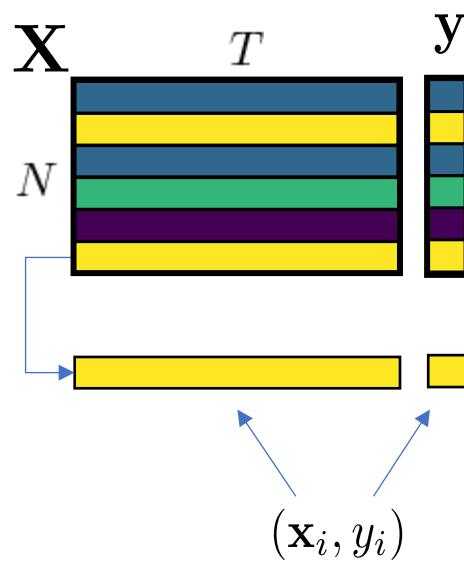
## Labels bzw. Targets

- Wir kennen schon unsere Feature-Matrix: nun assoziieren wir einen neuen Begriff mit dieser – ein **Label** oder **Target**
- Bei Labels handelt es sich um eine Variable, die **abhängige Variable**, die man aus den Features, den **unabhängigen Variablen**, vorhersagen will
- Labels können unterschiedliche Ausprägungen haben
  - **Klassifikation:** Labels haben eine **diskrete** Ausprägung
  - **Regression:** Labels haben eine **kontinuierliche** Ausprägung




In den Abbildungen:  
Farbe == Label

# Supervised Learning: mathematische Notation



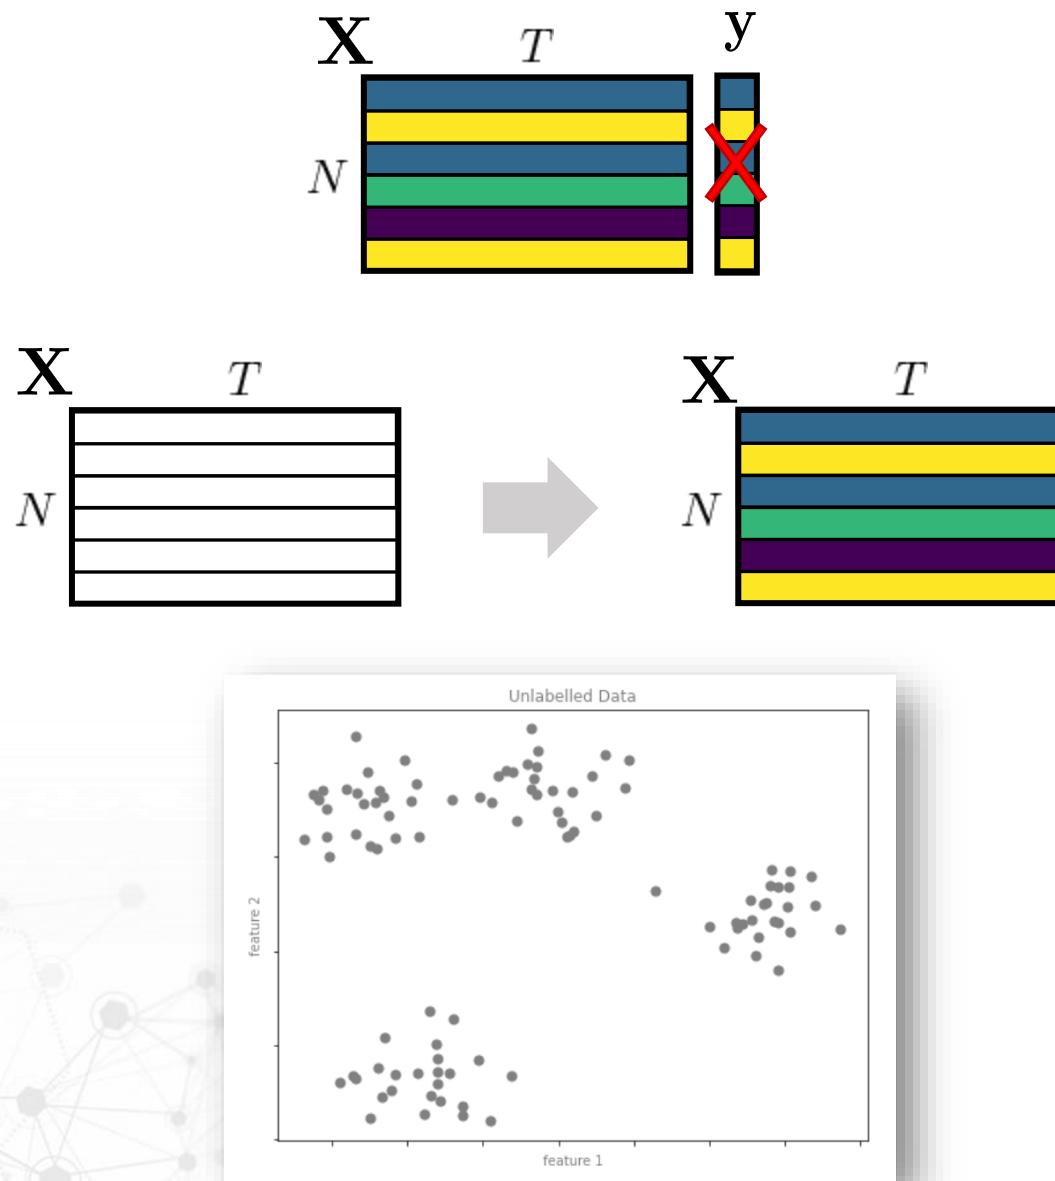
- Unsere Feature-Matrix beschreiben wir – wie gewohnt – durch ein  $\mathbf{X}$  mit den Dimensionen  $N \times T$
- Das zugehörige Label ist ein  $N$ -dimensionaler Spaltenvektor  $\mathbf{y}$
- Im sog. **Trainingsdatensatz** existiert zu jeder Beobachtung (Zeile der Feature-Matrix) ein Eintrag im Label-Vektor
- Wenn wir die Feature-Matrix als eine Menge an gestapelten Zeilenvektoren  $\mathbf{x}_i$  betrachten, dann liegt also folgende Assoziation vor  $(\mathbf{x}_i, y_i)$



## Trainingsdatensatz

- Unter diesem Begriff versteht man die Daten (und Labels), anhand derer das Machine Learning Modell **trainiert** wird
- An diesem wird also die Abhängigkeit der Labels von den Features geschätzt


# Unsupervised Learning: Datensicht



Unsupervised Learning == Keine Labels!


- Beim Unsupervised Learning liegen uns keine Labels vor
- Die, dem Datensatz zugrundeliegende Struktur, ist für uns (anfänglich) nicht ersichtlich bzw. markiert
- Wir haben es also mit einer „nicht eingefärbten“ Feature-Matrix zu tun
- Durch unsere Unsupervised Learning Modelle versuchen wir die Einfärbung zu schätzen

# Unsupervised Learning: mathematische Notation



- Wir haben also im Unsupervised Learning Fall (zuerst) nur eine Feature-Matrix  $\mathbf{X}$
- Das Machine Learning Modell versucht in diesem Fall Strukturen bzw. Muster in den Daten zu entdecken
- Wir können diese Muster dann auch mit Labels  $\mathbf{y}$  versehen
- Nachdem das Modell trainiert wurde, können auch im Unsupervised Learning Fall neue, ungesehene Daten den entdeckten Strukturen bzw. Muster zugeordnet werden

# Supervised Learning: Klassifikation




- Unsere Aufgabe bei einer Klassifikation ist: wir haben einen gelabelten Datensatz vorliegen (Trainingsdatensatz)
- Daran trainieren wir unser Machine Learning Modell
- Unser Modell soll dann **ungelabelte** Datenpunkte **klassifizieren** → Labels zuweisen

## Beispiel

- In unserem Beispiel liegen zweidimensionale Daten vor, die auf zwei Kategorien aufgeteilt sind (blau und rot)
- Unser Modell soll soz. eine „Trennlinie“ finden, die die beiden Klassen aufteilt
- Neue Daten können dann anhand dieser Trennlinie bewertet werden, ob sie in die blaue oder rote Kategorie fallen
- Die **Modellparameter** wären in diesem Fall die Koeffizienten der Geraden
- Diese Modellparameter werden aus den Daten **gelernt**

0  
So what?  
„Learning is finding parameters.“

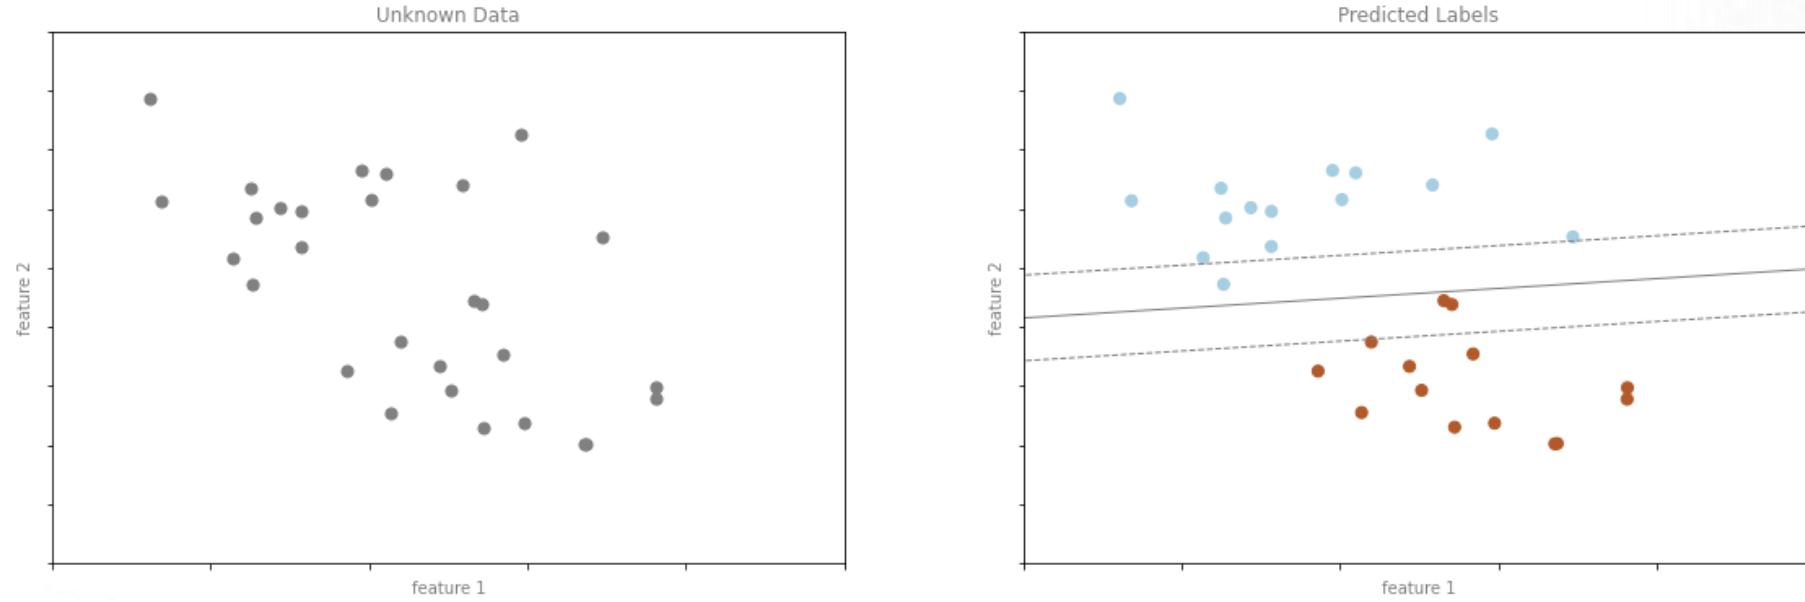
# Konzepte des Machine Learning: Scoring bzw. Prediction



- Wir haben nun schon kennengelernt, dass aus dem Training ein Modell entsteht, das die Beziehung zwischen Features und Labels abbildet
- Ziel beim Machine Learning ist dieses gelernte Wissen auf **neue, vorher ungesehene** Daten, anzuwenden
- Man führt dem Modell neue Beobachtungen zu und dieses bewertet diese dann  
→ Das Modell weist den neuen Beobachtungen Labels zu

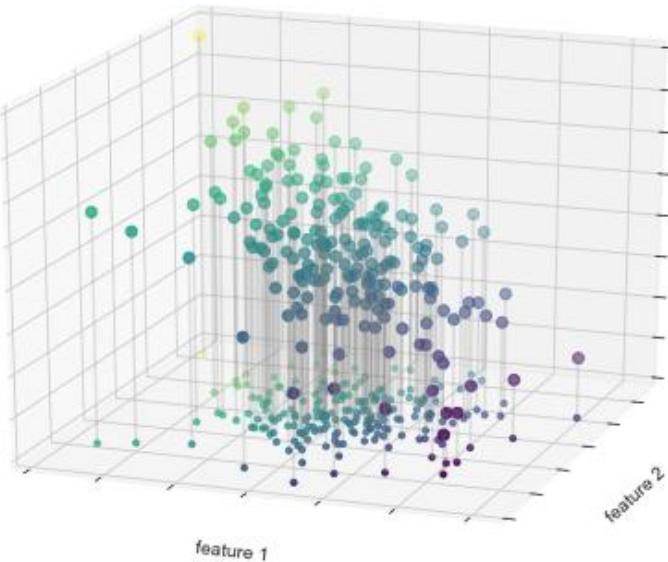
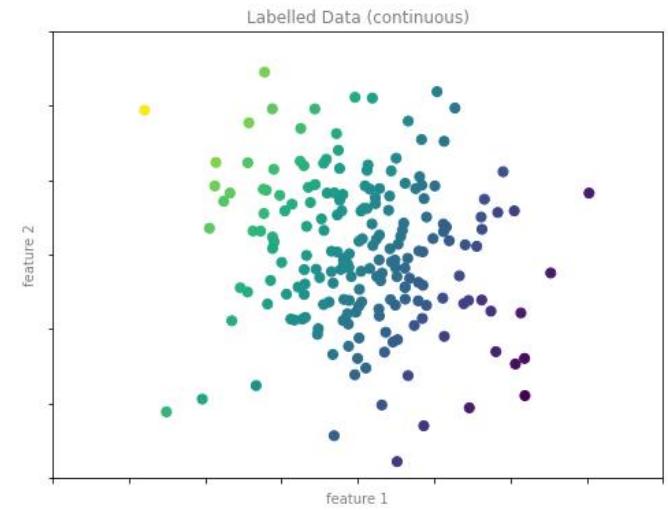
Diese Zuweisung von Labels auf neue Beobachtungen nennt man Scoring bzw. Prediction

# Supervised Learning: Klassifikation

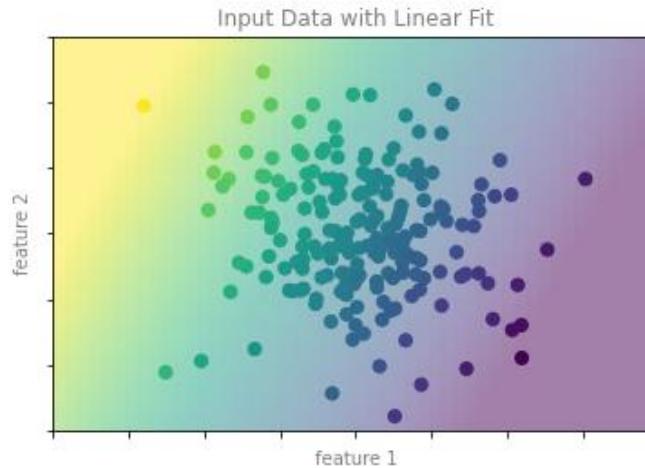


- Scoring bzw. Prediction wird in unserem Beispiel so durchgeführt, dass neue, unbekannte Daten mit dem Modell (unsere gelernte Gerade) **verglichen** werden
- Je nachdem auf welcher Seite der Gerade die Datenpunkte liegen, werden die entsprechenden **diskreten Labels** (rot oder blau) zugeordnet

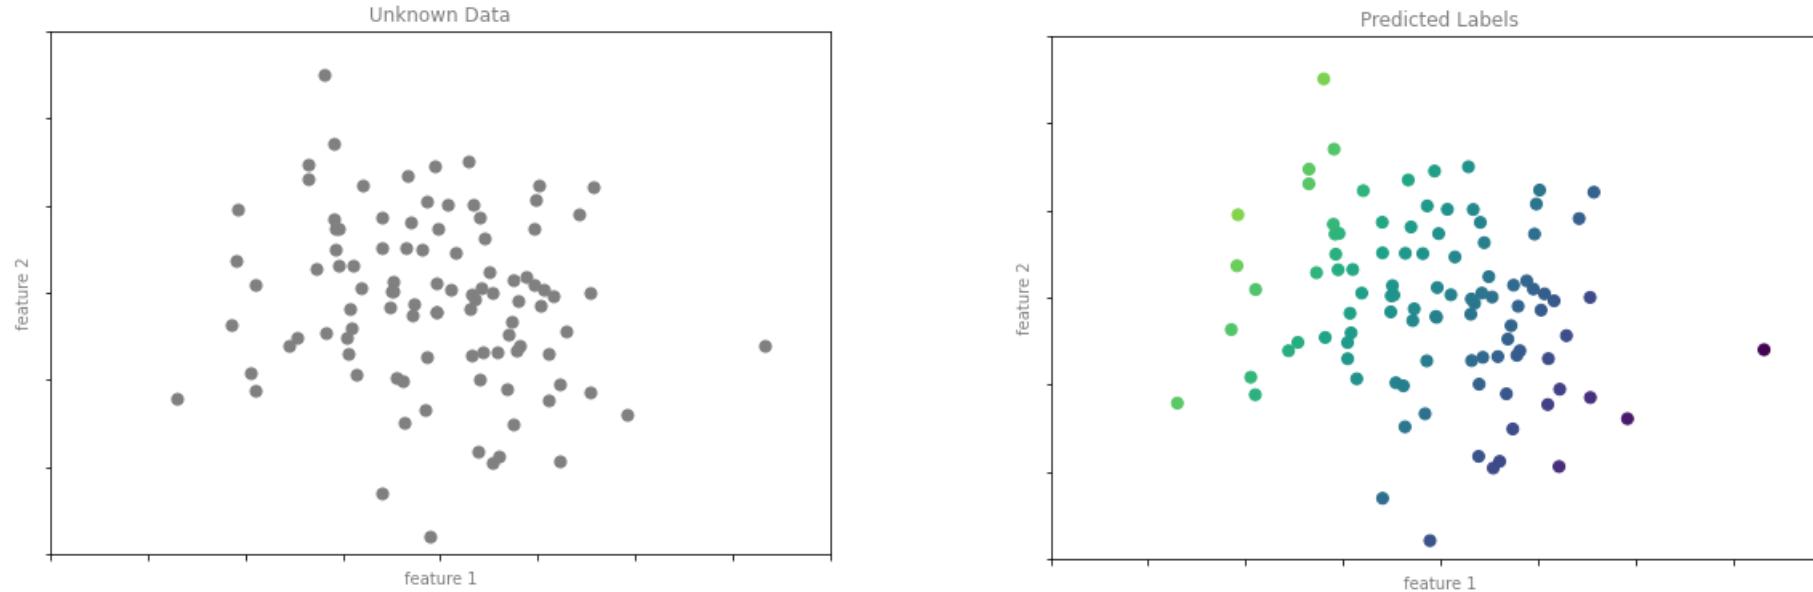
# Supervised Learning: Regression



- Im Gegensatz zur Klassifikation liegen uns bei der Regression **kontinuierliche** Labels vor
- In unserem zweidimensionalen Feature-Raum können wir uns das Label dann als eine **dritte Dimension** vorstellen
- Bei einer einfachen Regression würde man dann versuchen eine **Ebene** auf diese Daten zu fitten



# Supervised Learning: Regression: Scoring



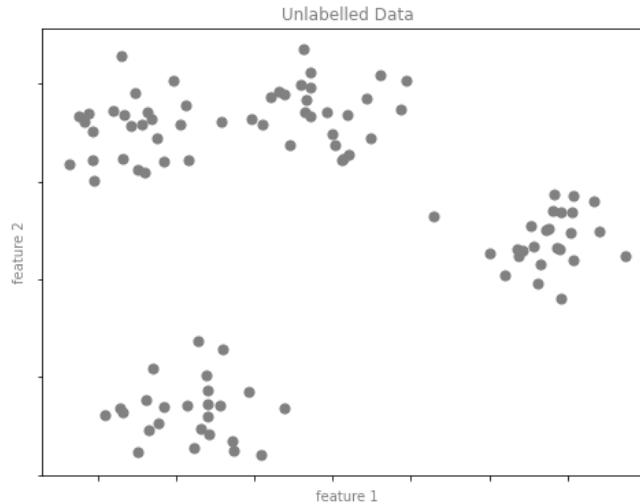
- Beim Scoring im Regressionsfall werden die unbekannten Daten soz. auf die geschätzte Ebene **projiziert**
- Dies liefert uns dann die **neuen**, kontinuierlichen **Labels** für die ungelabelten, neuen Daten

# Unsupervised Learning: Clustering



Was denken Sie?

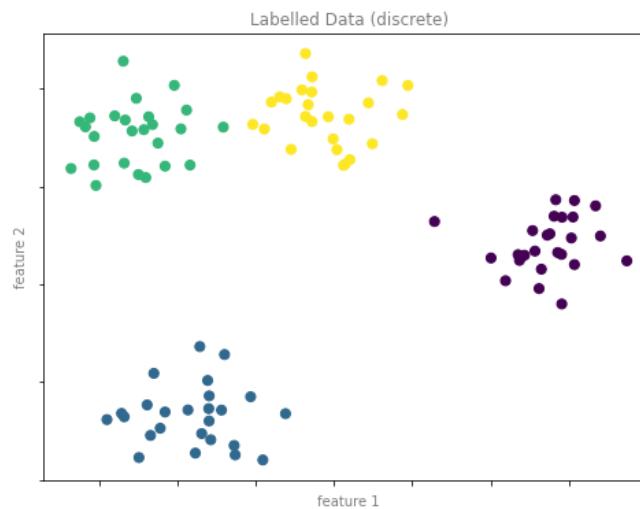
Wie würden Sie abschätzen, ob ein Datenpunkt zu einem bestimmten Cluster gehört? Welches Maß würden Sie verwenden?



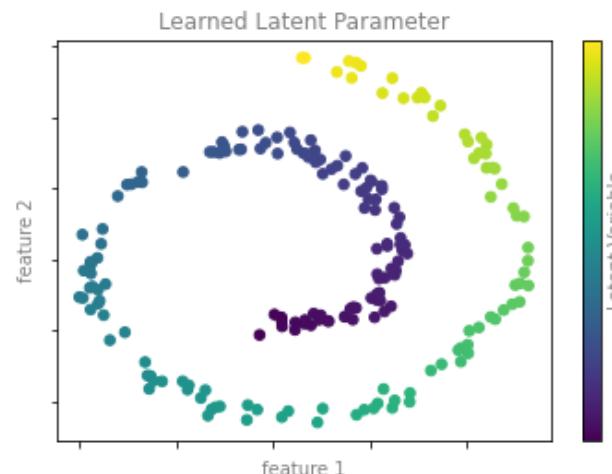
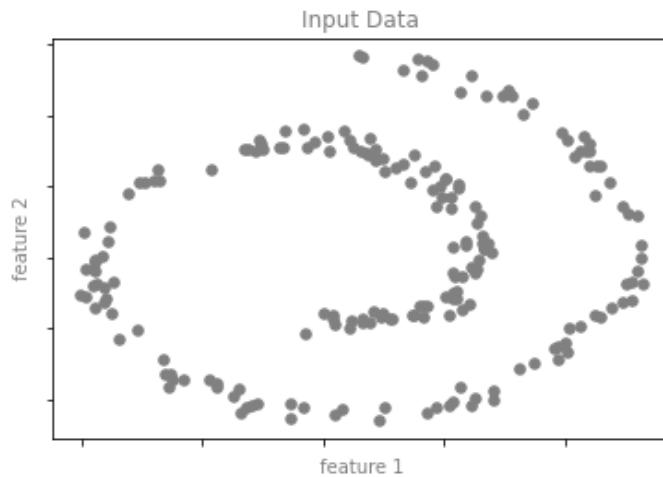
- Ein typisches Unsupervised Learning Problem ist **Clustering**
- Beim Clustering werden die ungelabelten Daten **diskreten Gruppen bzw. Labels** zugeordnet
- Clustering ist eng verwandt mit der **Dichteschätzung** der zugrundeliegenden Daten
- Neue Datenpunkte können dann z.B. durch **Abstandsbetrachtungen** einem bestimmten Cluster zugewiesen werden



Was denken Sie?  
Welches Problem  
sehen Sie hier?



# Unsupervised Learning: Dimensionsreduktion



- Ein weiteres Problem des Unsupervised Learnings ist die Dimensionsreduktion
- Ziel ist eine **niedrigdimensionale** Repräsentation der Daten, die die meisten/wichtigsten Eigenschaften dieser erhält
- In unserem Beispiel sehen wir schon visuell, dass eine bestimmte Struktur in den Daten vorhanden ist
- Diese Daten liegen auf einer Spirale – sind also intrinsisch **eindimensional**!
- Die Farbe entspricht einer sog. **latenten Variable** → Eine neue Koordinatenachse, die das Modell entdeckt/gelernt hat

# Machine Learning in Python

scikit-Learn