

# Modeling

---

Supervised Learning: Support Vector Machines

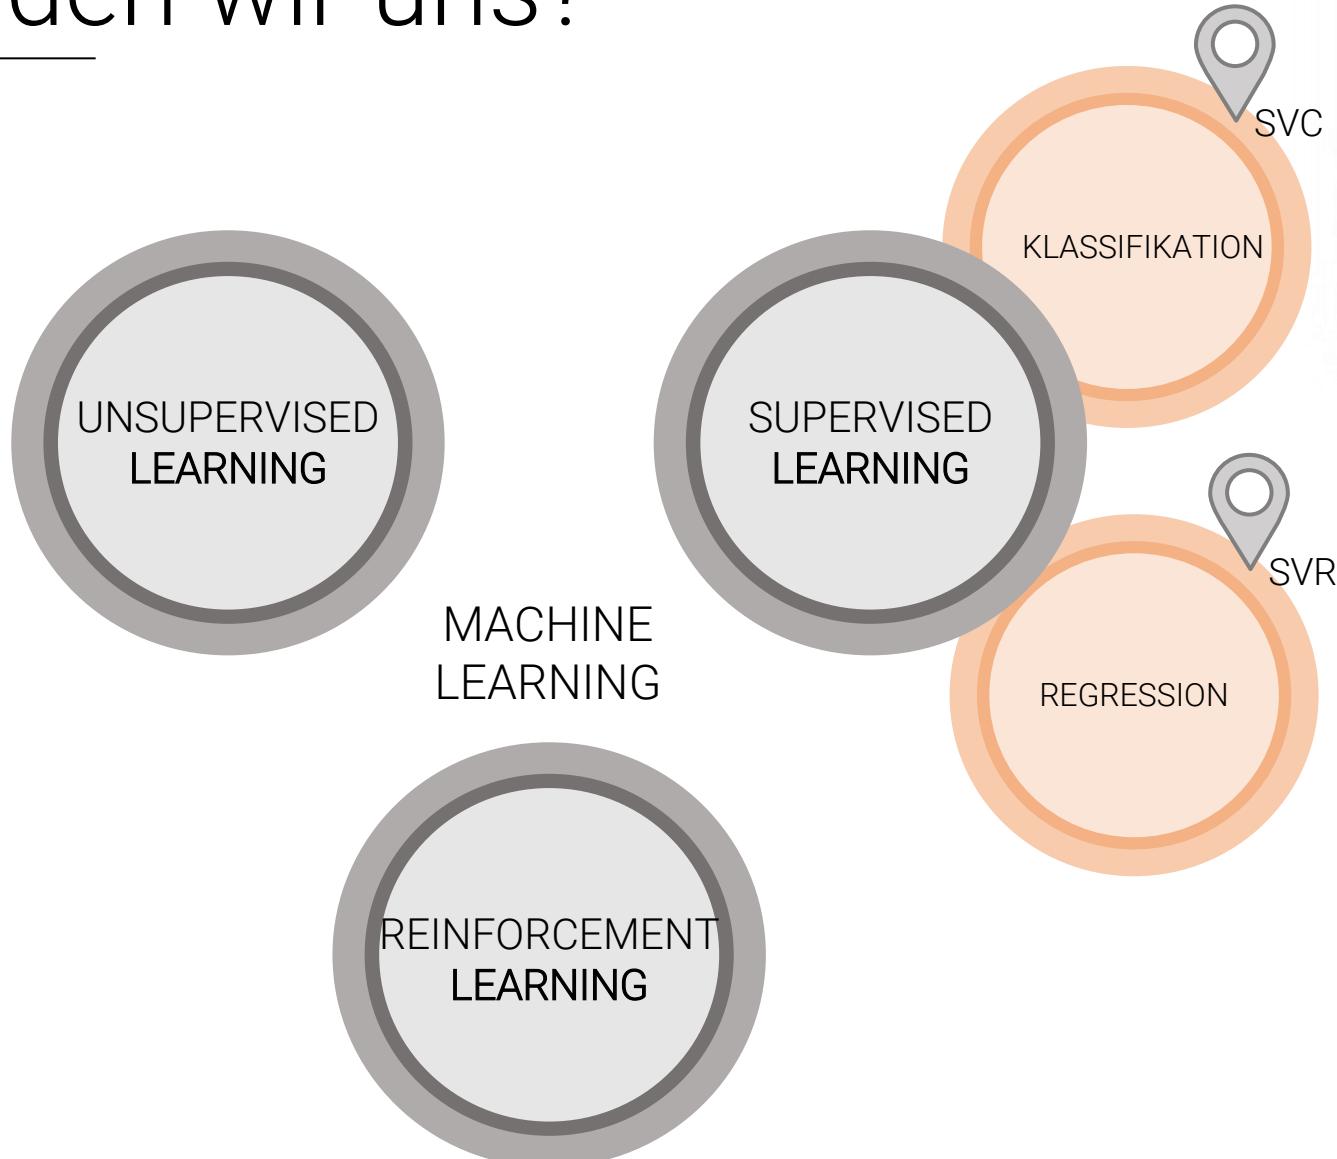
# Agenda

---

- 
1. SVM: Margin Maximierung und Support Vectors
  2. Mathematischer Hintergrund zu SVMs
  3. Soft-Margin SVM und Optimierung
  4. Nicht-lineare Probleme und Kernel-Trick



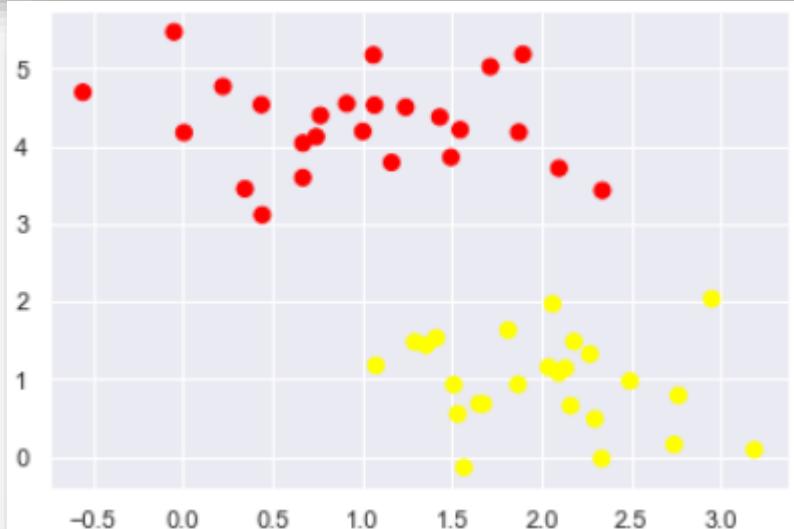
# SVM: wo befinden wir uns?



# SVM: allgemein



```
1 from sklearn.datasets.samples_generator import make_blobs  
2 X, y = make_blobs(n_samples=50, centers=2,  
3                     random_state=0, cluster_std=0.60)  
4 plt.scatter(X[:, 0], X[:, 1], c=y, s=50, cmap='autumn');
```



Unsere Ausgangssituation:

Zwei Klassen in einem 2D-Featureraum, die wir mit einem Klassifikator zu trennen versuchen



Was denken Sie?

Welches Problem sehen wir hier sofort?

- Support Vector Machines (**SVM**) sind eine der bekanntesten Modelle im Machine Learning
- Vor allem für **klein- und mittelgroße** Datensätze geeignet
- Sie sind flexibel und können für Klassifikations- und Regressionsprobleme verwendet werden
- SVMs stellen im Kontext der Klassifikation *diskriminative Klassifikatoren* dar



Was denken Sie?

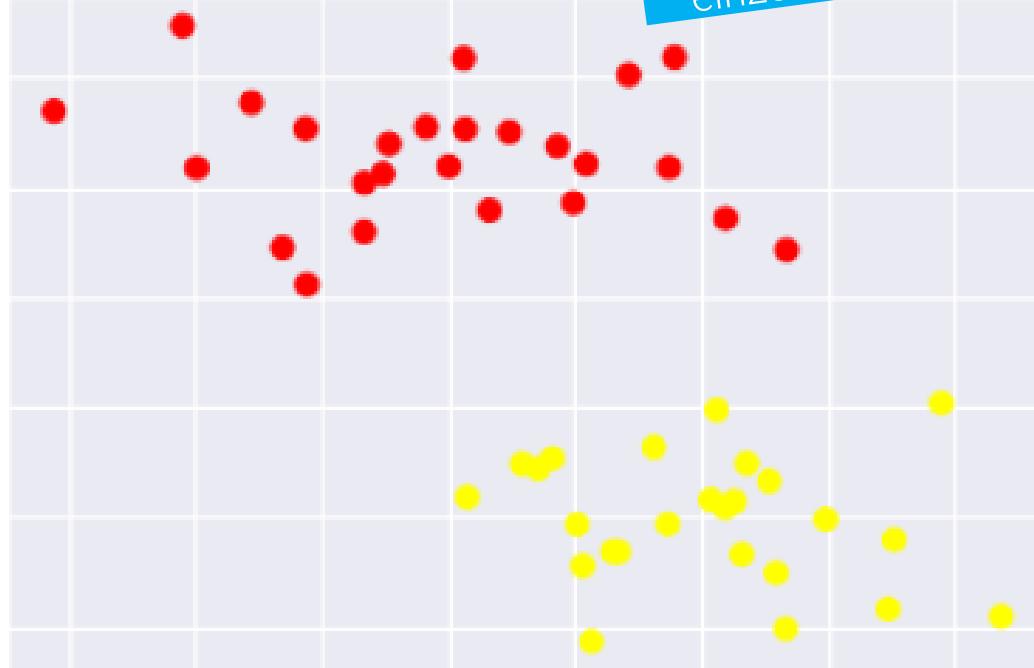
Was heißt diskriminativ?

# Wir als Klassifikatoren

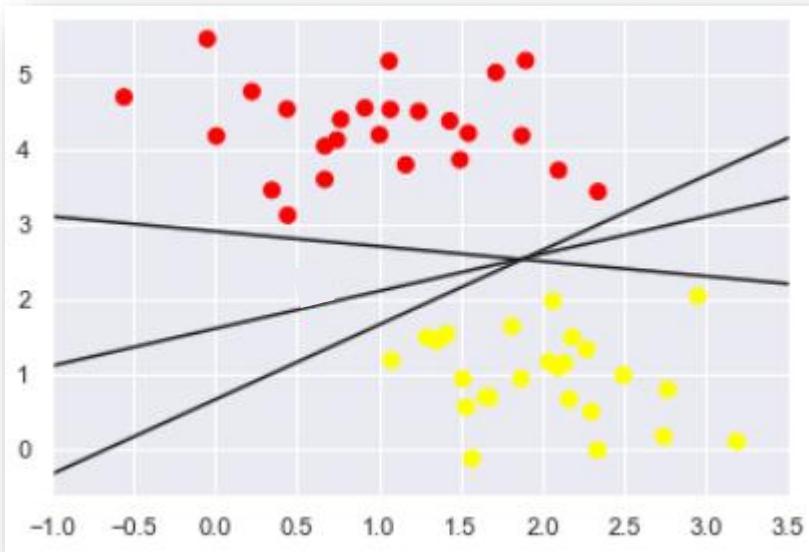


Was denken Sie?

Wie würden Sie – als Klassifikator  
– eine optimale Trennlinie  
einzeichnen? (Zoom: zeichnen)



# SVM: allgemein



- Wir können also beliebig viele Geraden einzeichnen, die unsere Klassen trennen
- Alle drei Geraden separieren unsere Klassen quasi ideal
- Wie sieht es nun mit **neuen Datenpunkten** aus? Je nachdem welche Gerade wir in unsere Ausgangssituation legen, können neue Datenpunkte unterschiedlich klassifiziert werden

```
1 xfit = np.linspace(-1, 3.5)
2 plt.scatter(X[:, 0], X[:, 1], c=y, s=50, cmap='autumn')
3 plt.plot([0.6], [2.1], 'x', color='red', markeredgewidth=2, markersize=10)
4
5 for m, b in [(1, 0.65), (0.5, 1.6), (-0.2, 2.9)]:
6     plt.plot(xfit, m * xfit + b, '-k')
7
8 plt.xlim(-1, 3.5);
```



Was denken Sie?

Wie würden Sie intuitiv das „x“ zuordnen – je nach Gerade?



Was denken Sie?

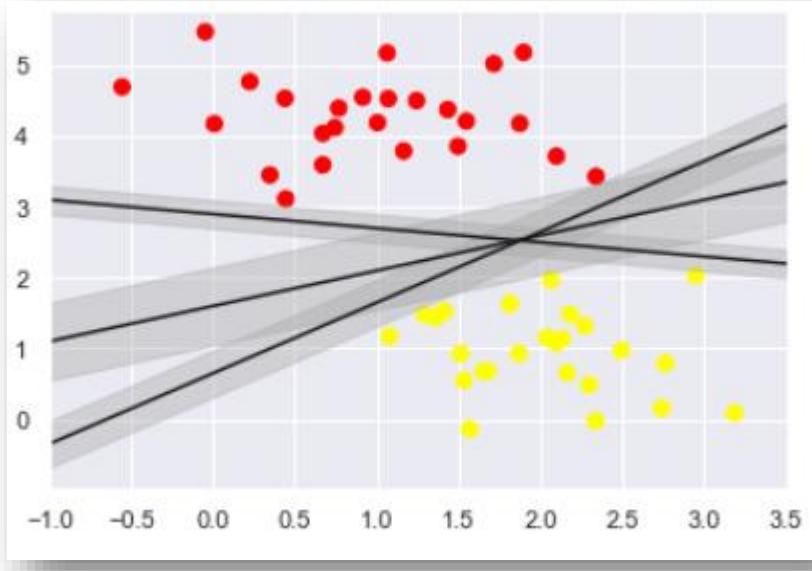
Wie würden Sie intuitiv entscheiden, welche Gerade die beste ist?

# SVM: Margin Maximierung



Was denken Sie?

Was könnte man noch tun – außer nur eine Gerade zu zeichnen?



```
1 xfit = np.linspace(-1, 3.5)
2 plt.scatter(X[:, 0], X[:, 1], c=y, s=50, cmap='autumn')
3
4 for m, b, d in [(1, 0.65, 0.33), (0.5, 1.6, 0.55), (-0.2, 2.9, 0.2)]:
5     yfit = m * xfit + b
6     plt.plot(xfit, yfit, '-k')
7     plt.fill_between(xfit, yfit - d, yfit + d, edgecolor='none',
8                      color='#AAAAAA', alpha=0.4)
9
10 plt.xlim(-1, 3.5);
```

- Anstatt nur eine bloße Gerade zur Trennung der Klassen zu nutzen, wird ein sog. **Margin** (dt. Rand, Spanne) um die Gerade gelegt
- Dieser Margin wird bis zu den **nächstliegenden** Punkten der Klassen erweitert
- Die **optimale** Gerade ist dann die mit dem **größten** Margin

→ SVMs sind sog. *Maximum Margin Estimators*



Was denken Sie?

Welche Gerade wird wohl die beste sein – und warum?

# SVM: Fitting/Training

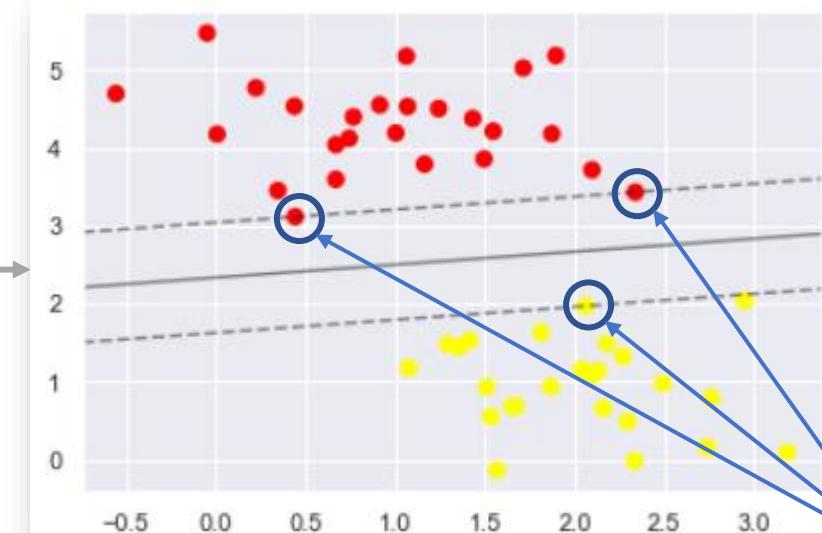
Modell

```
1 from sklearn.svm import SVC # "Support vector classifier"  
2 model = SVC(kernel='linear', C=1E10)  
3 model.fit(X, y)
```



Was denken Sie?

Können Sie sich vorstellen,  
woher das „Support  
Vector“ in SVM kommt?



Support Vectors

- Wie wir es bei der Einführung der `sklearn`-Syntax gelernt haben instanziieren wir das SVM Modell  
`SVC(kernel=<kernel_type>, C=<regularization_parameter_value>)`  
Was `kernel` und `C` repräsentieren lernen wir später
- Dann können wir die `.fit()`-Methode verwenden, um das Modell auf unsere Daten in `x` (Features) und `y` (Labels) anzupassen/fitten/trainieren
- Dadurch erhalten wir die Trennlinie mit dem **maximalen Margin**, die unsere beiden Klassen am besten trennt
- SVC bedeutet **Support Vector Classifier** – SVMs können also auch **regressiv** verwendet werden, sehen wir später

# SVM: Support Vectors



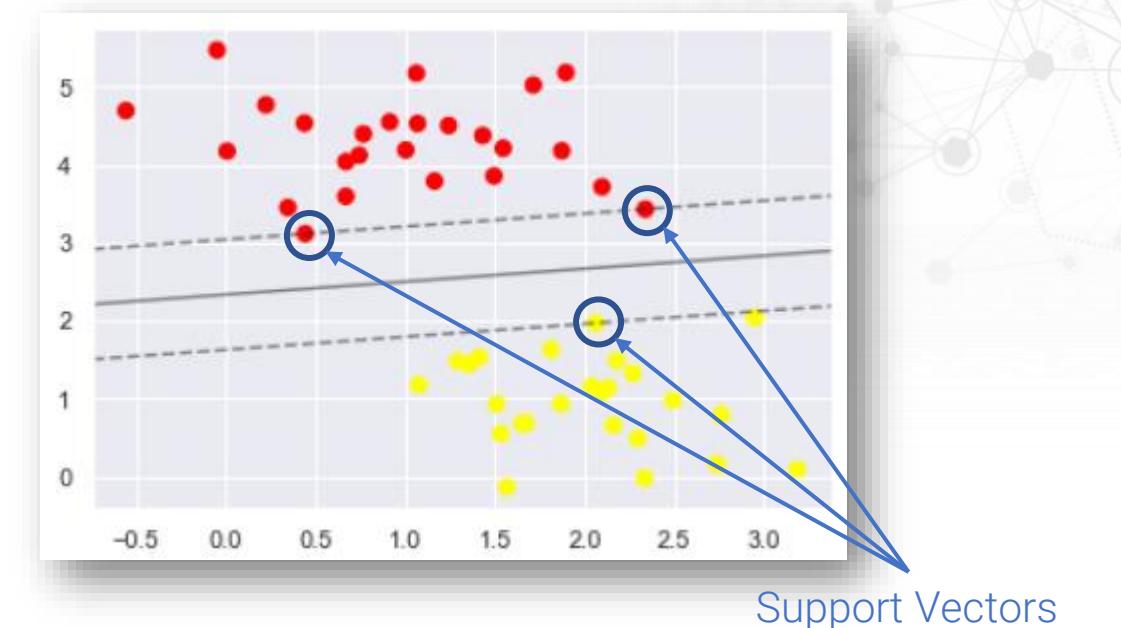
Was denken Sie?

Welchen? Von was  
hängt das Modell ab?

```
1 model.support_vectors_
```

```
array([[ 0.44359863,  3.11530945],  
       [ 2.33812285,  3.43116792],  
       [ 2.06156753,  1.96918596]])
```

- Diese Support Vectors stellen einen entscheidenden Aspekt dieses ML-Modells dar
- Der Fit des Modells hängt **nur** von diesen Datenpunkten ab!
- Wir können über das Attribut `.support_vectors_` auf diese zugreifen



So what?

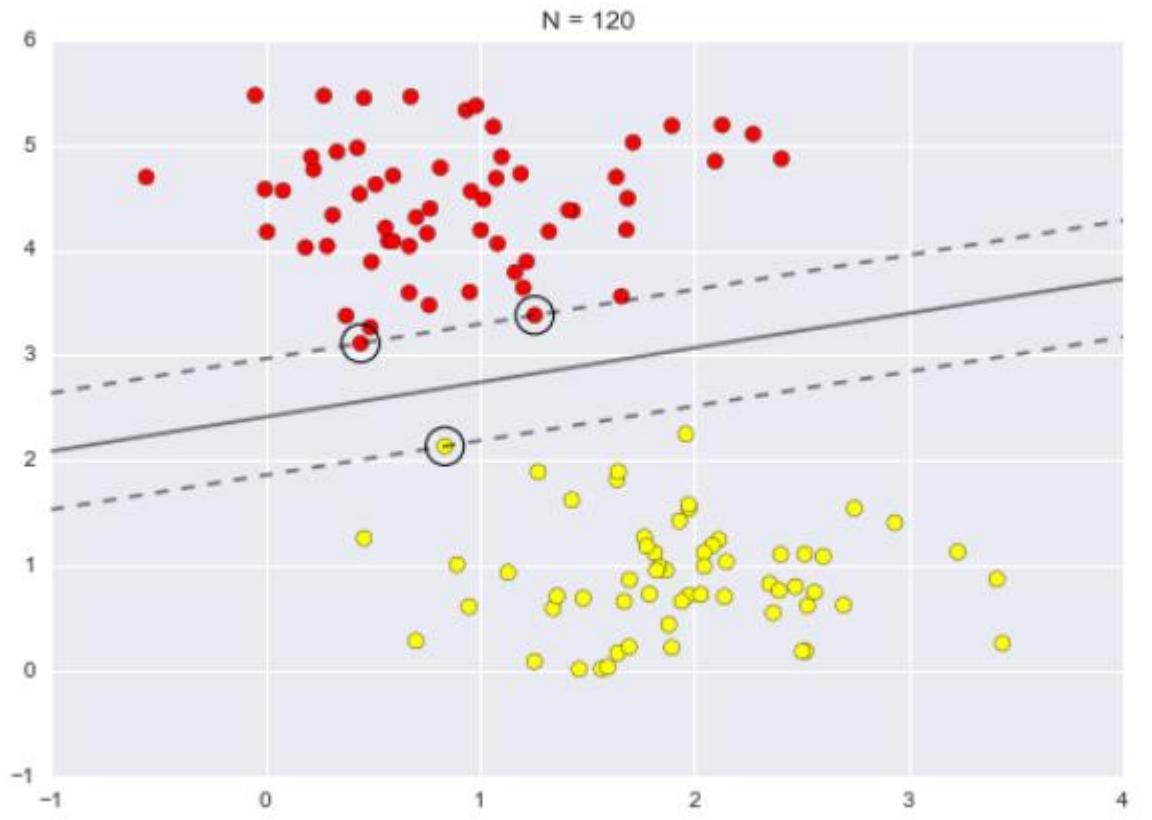
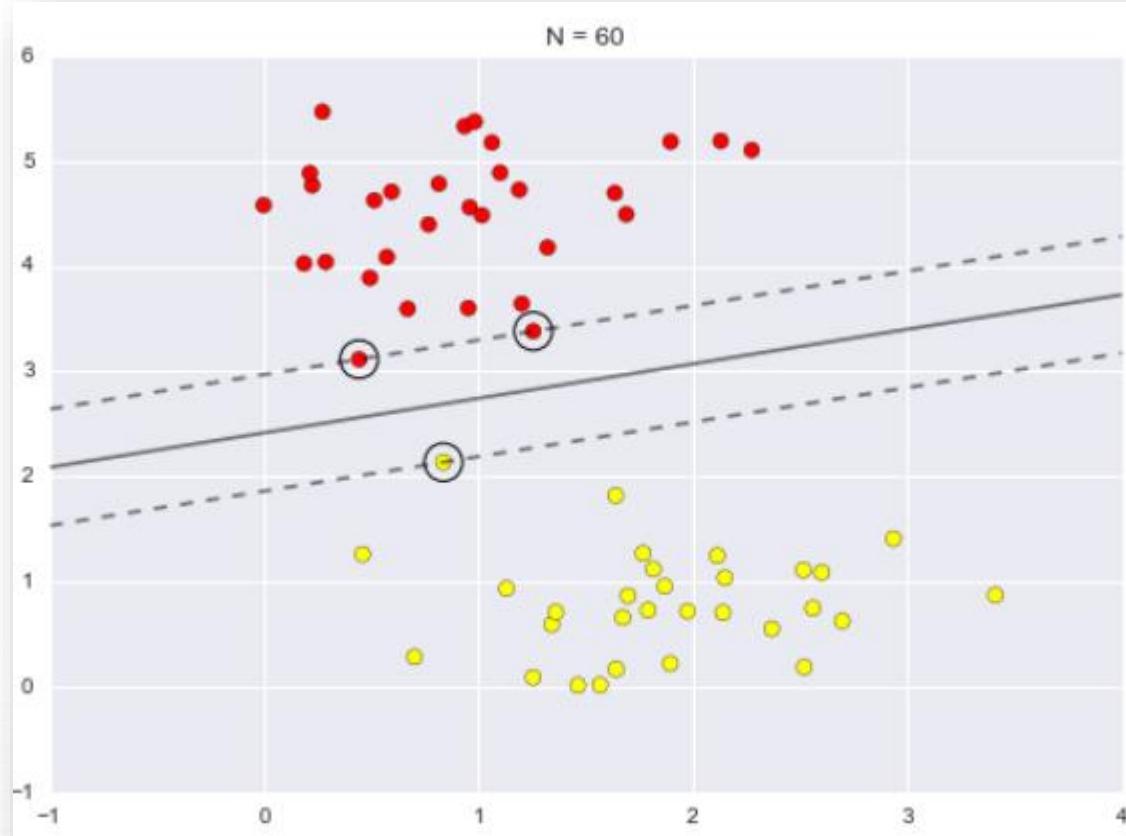
In höheren Dimensionen spricht man nicht mehr von Geraden, sondern Hyperebenen, die unsere Klassen trennen



Was denken Sie?

Wie sieht unser Modell in höheren Dimensionen aus?

# SVM: Support Vectors



*So what?*

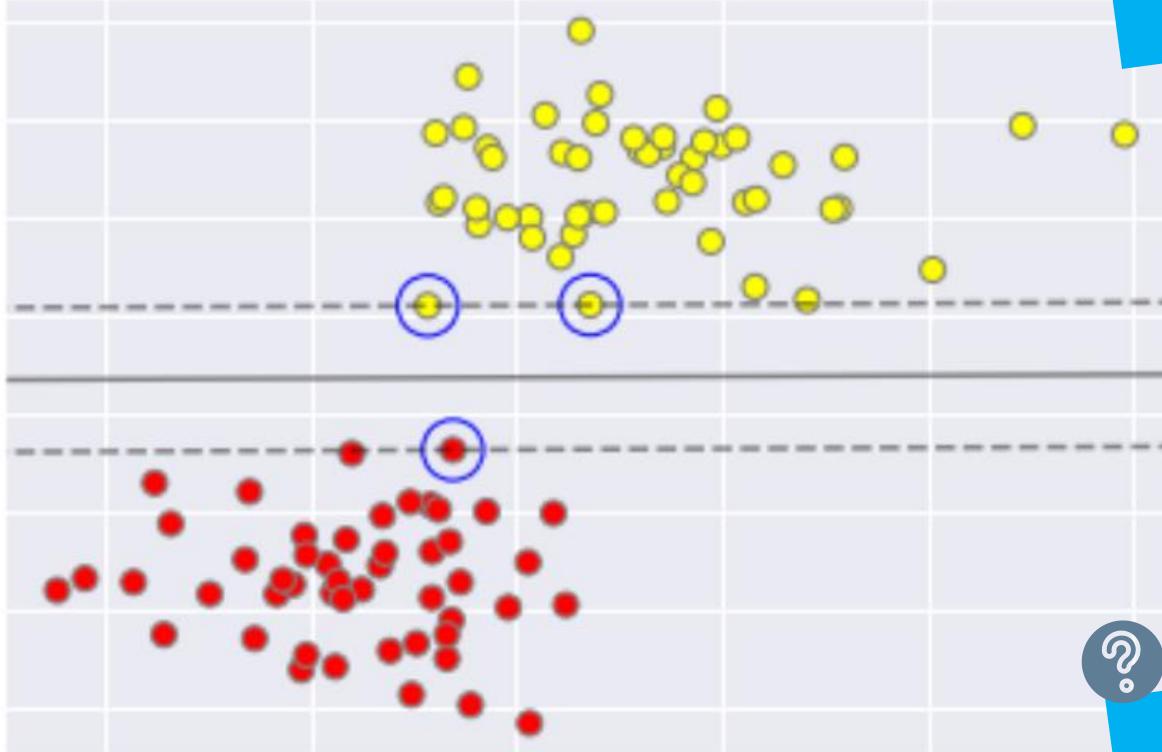
Diese Unempfindlichkeit des Modells auf entfernt liegende Punkt ist eine der Stärken dieser Art ML-Modelle

# Wir als Klassifikatoren 2.0



Was denken Sie?

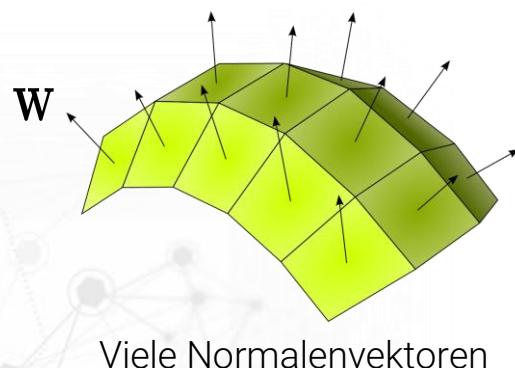
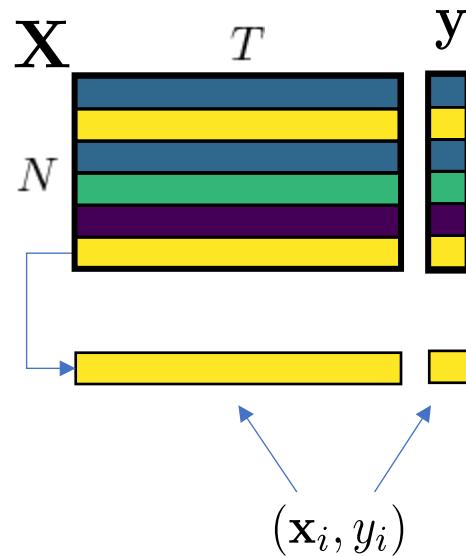
Wie würden Sie nun – als Klassifikator – eine optimale Trennlinie einzeichnen?  
(Zoom: zeichnen)



Was denken Sie?

Was sind die Support Vektoren? (Zoom: zeichnen)

# SVM: Mathematik



Uns liegt ein historischer Datensatz bzw. Trainingsdatensatz vor

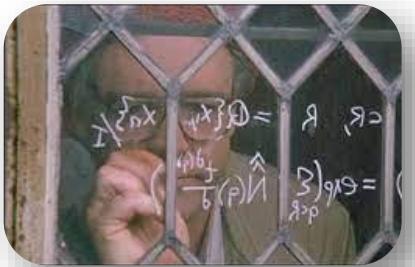
$$\{(\mathbf{x}_i, y_i) | i = 1, \dots, N, y_i \in \{-1, 1\}\}$$

Anhand dessen wird unsere Hyperebene gelernt. Wir beschreiben unsere Hyperebene mittels des Normalenvektors  $\mathbf{W}$  durch den Ursprung

und des Abstandes vom Ursprung  $b$ , den man *Bias* nennt

Mit diesen beiden Informationen haben wir eindeutig eine Hyperebene im Raum definiert

# SVM: Mathematik



Fenster Time!



Was denken Sie?

Wie berechnet man  
also die Klassen/Labels  
neuer Daten?



Was denken Sie?

Was sucht also der  
Trainingsprozess?

Für die Datenpunkte auf der Hyperebene gilt

$$\langle \mathbf{w}, \mathbf{x}_i \rangle + b = 0$$



Was denken Sie?

Wie drückt man das  
in einer Formel aus?



Was denken Sie?

Was gilt für Punkte,  
die nicht auf der  
Hyperebene liegen?



Was denken Sie?

Wie könnten wir das  
mit einer Ungleichung  
ausdrücken?



Wenn also eine Hyperebene **alle Punkte** unserer Klassen voneinander **trennt**,

dann weisen die Punkte einer Klasse alle entweder **positive** oder **negative**

Vorzeichen auf

Für unsere Klassen gilt dann also

$$y_i = \text{sgn}(\langle \mathbf{w}, \mathbf{x}_i \rangle + b)$$

$$y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 0$$



Unser Modell!

Aus den unendlich vielen Hyperebenen wählt man nun die, die den größten  
Margin zwischen den beiden Klassen aufweist



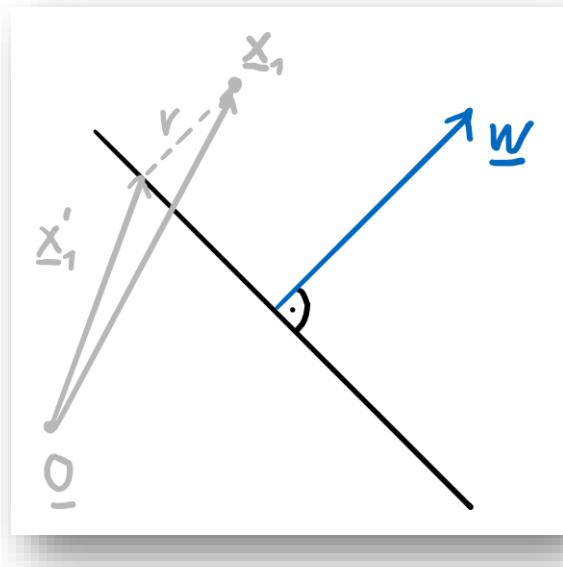
Was denken Sie?

Warum soll der Margin  
maximiert werden?

# SVM: Mathematik



$$\mathbf{x}_1 = \mathbf{x}'_1 + r \frac{\mathbf{w}}{\|\mathbf{w}\|}$$



So what?

Wir versuchen nun sukzessive dieses Optimierungsproblem zu vereinfachen. Was heißt hier vereinfachen?

Was bedeutet ein **maximaler Margin** mathematisch für uns?

Der Margin wird durch den **Abstand** zu den **nächsten** Punkten der Klassen zur Hyperebene definiert – wir brauchen also einen Abstand

Mit diesem Abstand  $r$  können wir nun unsere **Bedingung**, auf den jeweiligen Seiten der Hyperebene **nur Datenpunkte je einer Klasse** vorzufinden formulieren

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq r$$

Wir können nun ein **Optimierungsproblem** formulieren

$$\max_{\mathbf{w}, b} r$$

unter den **Bedingungen**

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq r \quad \|\mathbf{w}\| = 1 \quad r > 0$$

# SVM: Mathematik



Was denken Sie?

Wieso heißen  
diese Bedingungen  
Hard Margin?

Der Normalenvektor sei nun **nicht mehr normalisiert**. Um das Optimierungsproblem *berechenbar* zu machen, müssen wir eine kleine Umformung machen: durch eine **Skalierung** der Daten auf die Bedingung

$$\langle \mathbf{w}, \mathbf{x}_a \rangle + b = 1$$

mit  $\mathbf{x}_a$  als der nächste Punkt zur Hyperebene (Support Vector) und den vorher definierten Abstand kann gezeigt werden, dass

$$r = \frac{1}{\|\mathbf{w}\|}$$

und für unsere Bedingung gilt dann

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1$$

Damit reduziert sich unser Problem auf

$$\max_{\mathbf{w}, b} \frac{1}{\|\mathbf{w}\|} \quad \text{bzw.} \quad \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

unter der Bedingung

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1$$

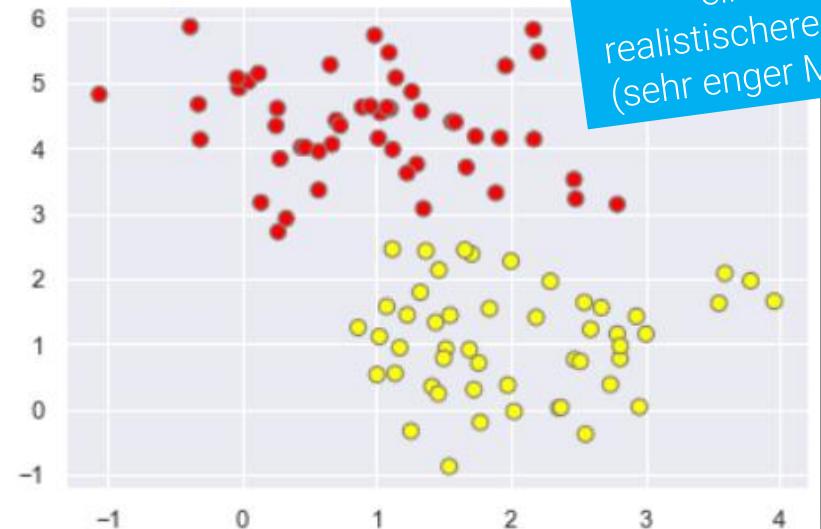


# SVM: Hard- und Soft-Margin



Was denken Sie?

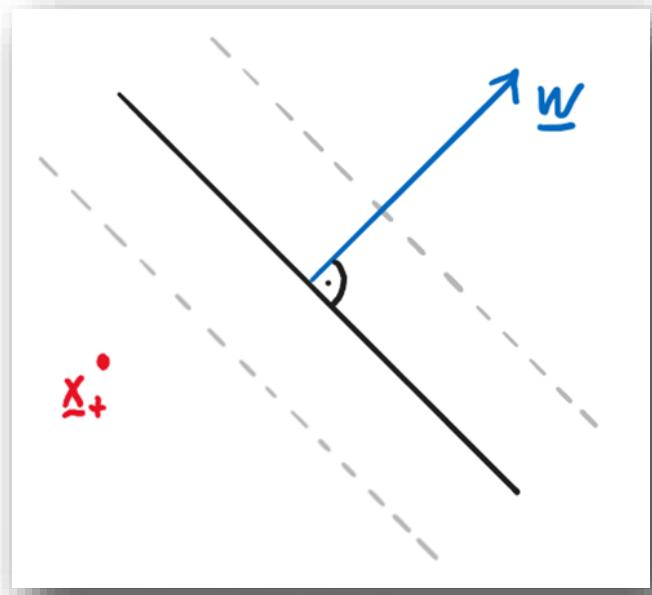
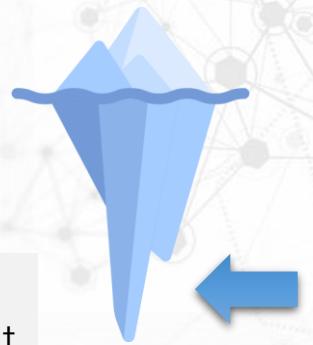
Was tun Sie in so  
einem –  
realistischeren – Fall  
(sehr enger Margin)?



```
1 X, y = make_blobs(n_samples=100, centers=2,  
2                      random_state=0, cluster_std=0.8)  
3 plt.scatter(X[:, 0], X[:, 1], c=y, s=50, cmap='autumn', edgecolors='gray');
```

- Bei SVMs hat man die Möglichkeit die Margins entweder starr bzw. **hard** oder weich bzw. **soft** zu definieren
- In anderen Worten: lässt man zu, dass Datenpunkte **innerhalb** des Margins auftauchen dürfen – Leitfrage: **wie viele** bzw. zu welchem Ausmaß?
- Hierzu gibt es einen Hyperparameter, der getuned werden muss – in `sklearn` ist es das Argument `C`
- **Große** Werte entsprechen einem **Hard**-, **kleine** Werte einem **Soft-Margin**
- Der **optimale** Wert von `c` hängt also vom Datensatz ab und muss via z.B. Cross-Validation bestimmt werden  
→ Zuerst schauen wir, wo in der Mathematik dieses `C` zu finden ist

# SVM: Soft-Margin: Mathematik



Was denken Sie?  
Was ändern wir an unseren  
Formulierungen? Wie  
quantifizieren wir  
Verletzungen des Margins?

Wir führen eine sog. *Slack Variable* ein, die **bestraft** wenn ein Datenpunkt innerhalb des Margins bzw. auf der falschen Seite liegt – dies ermöglicht uns im Umkehrschluss: **Verletzungen des Margins werden zugelassen!**

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \xi_i$$

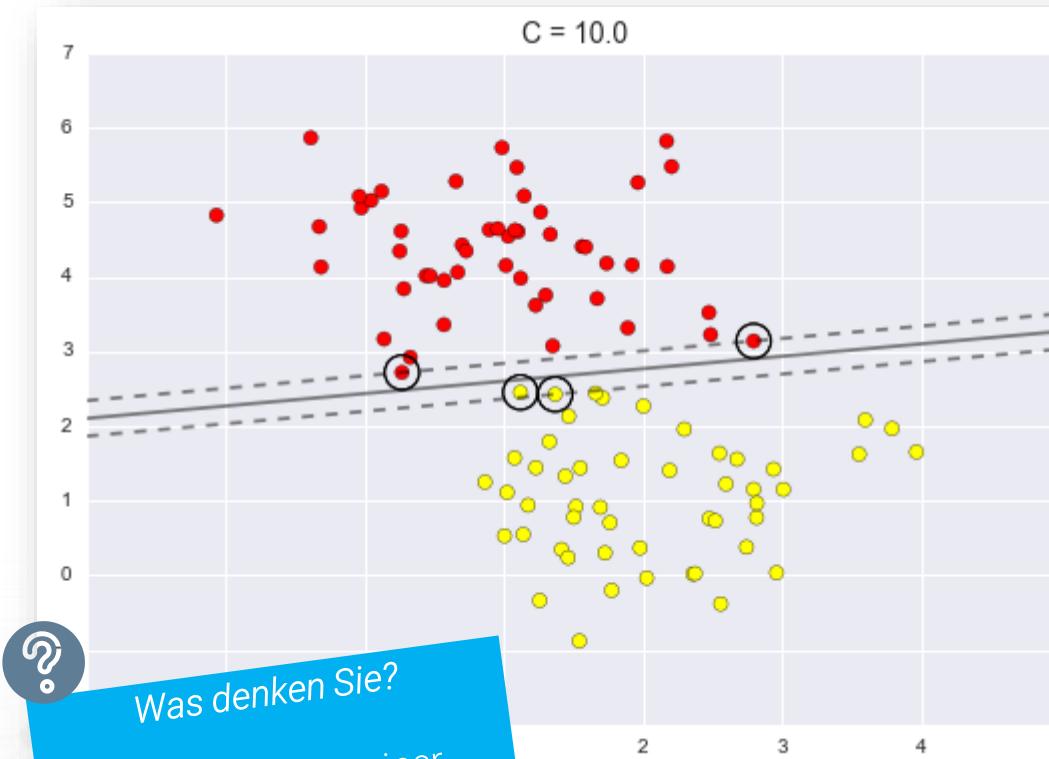
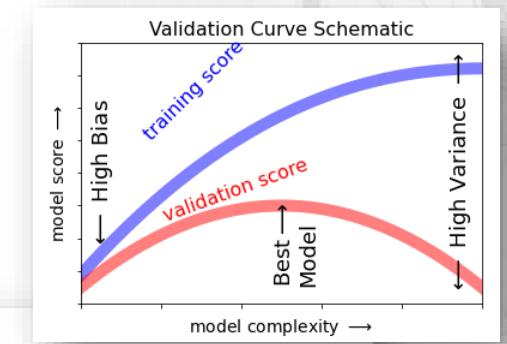
mit den Bedingungen

$$y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i \quad \text{und} \quad \xi_i \geq 0$$

Der Parameter  $C$  versucht also eine **Balance** bzw. einen **Trade-Off** zwischen „Größe des Margins“ und „Verletzung dessen“ herzustellen

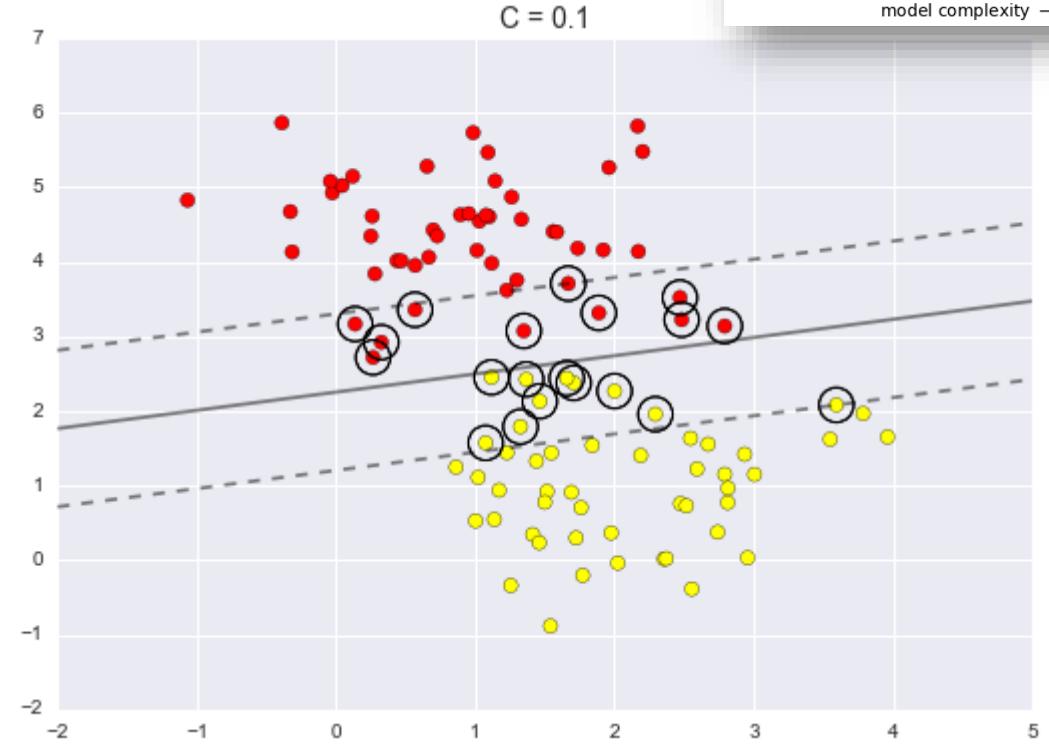
Zu diesem Parameter sagt man **Regularisierungsparameter**

# SVM: Hard- und Soft-Margin



Was denken Sie?

Was entspricht einer hohen, was einer niedrigen Modellkomplexität?

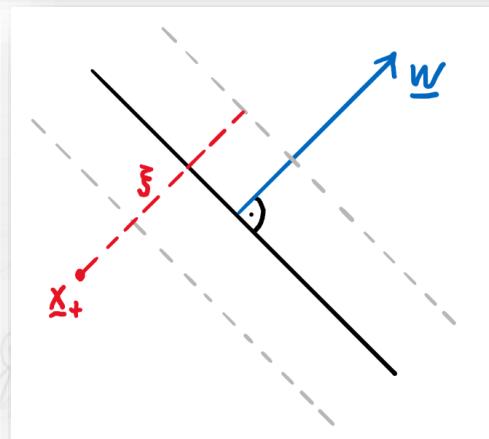
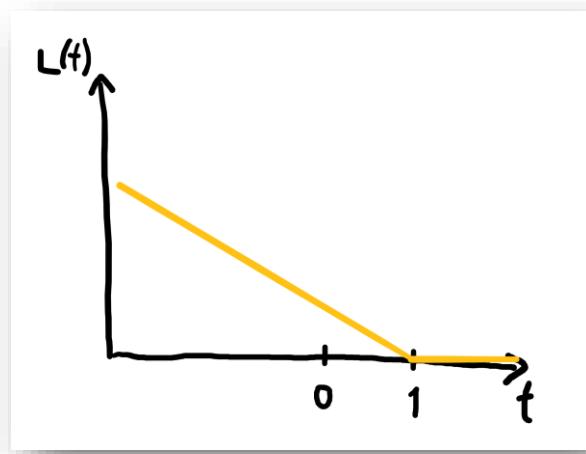


# SVM: Optimierung mittels Loss Function



Was denken Sie?

Wie würden Sie die Kostenfunktion aufstellen?



Die naheliegendste Formulierung einer Loss Function wäre die Accuracy – also: wie gut decken sich Vorhersage und Labels?

Diese ist jedoch ungeeignet, da es sich hierbei um ein sog. *kombinatorisches Optimierungsproblem* handelt

Eine kontinuierliche Loss Function ist also anzustreben – mögliche Formulierung: **Hinge Loss**

$$L(t) = \max\{0, 1 - t\} \quad \text{mit} \quad t = y f(\mathbf{x}) = y(\langle \mathbf{w}, \mathbf{x} \rangle + b)$$

Damit ergibt sich unser letztendlich **optimierbares** Problem zu

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \max\{0, 1 - y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b)\}$$

Hierzu sagt man auch **Regularisierung** – Margin Maximierung ist also Regularisierung



So what?

Durch diesen Hinge-Loss konnten wir die vorher eingeführte Slack-Variable wieder ersetzen und dadurch unser Optimierungsproblem vereinfachen.



Was denken Sie?

Wie schaut die math. Formulierung hierzu aus?



Was denken Sie?

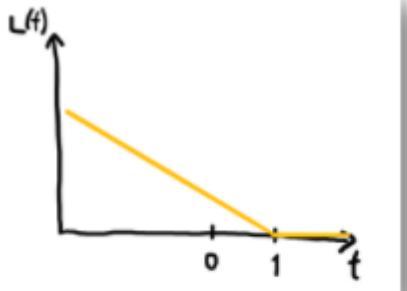
Wie leitet man die max-Funktion ab?

# Beispiel: SVM from Scratch: Loss Function



Was denken Sie?

Ohne es hier schon behandelt zu haben: haben Sie eine Vermutung wie man damit nun die optimalen Modellparameter findet?



Wir haben gesehen, dass man durch ein paar mathematische Umformungen zu einem übersichtlichen Optimierungsproblem bzw. einer relativ überschaubaren Kostenfunktion gelangt. Wir wollen uns nun in diesem Beispiel damit beschäftigen die Loss Function

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_i \max\{0, 1 - y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b)\}$$

als Funktion in Python abzubilden.



So what?

Nun wissen wir wie die SVM als mathematisches Modell aussieht und welche Kostenfunktion minimiert werden soll. Das Werkzeug für die Minimierung – z.B. den sog. Gradientenabstieg – sehen wir uns in einer späteren Veranstaltung an.